

# Estimación del volumen sólido de cargamentos de madera apilada mediante fotogrametría, reconstrucción 3D y redes neuronales convolucionales

García-Pascual, B.<sup>1</sup>,  
Acuna, M.<sup>2</sup>

<sup>1</sup> *föra forest technologies*

<sup>2</sup> *University of the Sunshine Coast, Australia*

Una parte importante del coste de las explotaciones forestales madereras se deriva del método de cubicación empleado. Como alternativa a la cubicación manual de madera apilada se han desarrollado nuevas tecnologías más eficientes que, sin embargo, resultan demasiado costosas. Por ello, han surgido técnicas basadas en sensores ópticos de bajo coste que aplican algoritmos de visión artificial e inteligencia artificial para obtener estimaciones del volumen de madera. En esta investigación, hemos desarrollado y validado un sistema automatizado de cubicación de madera de *Eucalyptus nitens* H. Deane & Maiden apilada sobre camiones usando imágenes tomadas con drones y técnicas de fotogrametría multivista (SfM) y de reconstrucción 3D. Además, hemos aplicado una red neuronal convolucional (CNN), denominada KPConv, para diferenciar el cargamento de madera de la estructura del camión a partir de nubes de puntos densas obtenidas mediante SfM. Los resultados preliminares de este estudio muestran que más del 83 % de la varianza del volumen sólido puede explicarse a partir del volumen bruto estimado por nuestro método.

**Palabras clave:** Automatización de procesos, fotogrametría, reconstrucción 3D, drones, planificación de operaciones, redes neuronales convolucionales, aprendizaje profundo

## INTRODUCCIÓN

La cubicación de pilas de madera se ha realizado tradicionalmente mediante técnicas ineficientes y costosas (JANÁK, 2005; 2007; KNYAZ & MAKSIMOV, 2014), lo que ha llevado al desarrollo de métodos sustitutivos basados en visión artificial. En este sentido, automatizar la cubicación de madera apilada durante el proceso de transporte resulta de gran interés, ya que permite minimizar el tiempo invertido en la medición de las pilas de madera sin interrumpir su traslado. Prueba de ello es el desarrollo de numerosos productos comerciales que permiten estimar el volumen sólido de madera acarreado por camiones de carga (MABEMA, 2020; P3D, 2020; WOODTECH, 2020; CIND AB, 2021). De entre estos métodos de medición, aquellos que emplean sensores láser son los que han alcanzado un mayor grado de madurez (Acuna y Sosa, 2019). Estos se basan en el escaneo de la carga del camión mientras atraviesa un pórtico en el que se sitúan una serie de sensores láser, lo que da lugar a una nube de puntos densa, donde cada punto posee unas coordenadas X, Y y Z definidas. A partir de esta nube se estima el volumen bruto del cargamento, además de ciertas métricas de las trozas periféricas, lo que permite ajustar un modelo de regresión y estimar el volumen sólido de madera (NYLINDER *et al.*, 2008).

No obstante, el coste de instalación y mantenimiento de los sistemas láser todavía resulta prohibitivo en algunos casos, lo que ha provocado la aparición de alternativas basadas en sensores ópticos, más económicos y fáciles de instalar (White *et al.*, 2016; Acuna y Sosa, 2019; Mitrofavnos *et al.*, 2019). Por ejemplo, algunos sistemas emplean varios pares de cámaras para generar la nube de puntos mediante técnicas de estereoscopía (Cind, 2021). Sin embargo, son los métodos basados en fotogrametría multivista, o "Structure from Motion" (SfM) los que han recibido más atención en los últimos años, debido principalmente al desarrollo de los vehículos aéreos no tripulados (UAV) y a la reducción de su precio (Gruen, 2008; Harwin y Lucieer, 2012). El SfM

es un algoritmo de visión artificial que permite reconstruir modelos 3D a partir de la superposición de múltiples imágenes tomadas desde diferentes ángulos. Para ello, se localizan los puntos comunes en las zonas solapadas de las imágenes y se emparejan según su similitud, lo que permite estimar la posición de la cámara en cada fotografía y generar una nube de puntos densa (Snavly *et al.*, 2008). Este método fue probado con éxito por Acuna y Sosa (2019) para estimar el volumen de madera sólido contenido en diez camiones de carga. Con ese fin, tomaron un promedio de 48 imágenes de cada camión desde diversos puntos de vista, las cuales sirvieron para generar una nube de puntos densa. Tras esto, reconstruyeron la superficie de los camiones, lo que permitió estimar el volumen bruto del cargamento. Finalmente, ajustaron un modelo de regresión para estimar el volumen sólido de madera a partir del volumen bruto del cargamento. Como resultado, reportaron errores comparables a los obtenidos mediante escaneo láser (Nylander *et al.*, 2008). Por ende, teniendo en cuenta que el coste de los sensores láser es varias veces superior al de los sensores ópticos (Mlambo *et al.*, 2017), los métodos de cubicación mediante SfM se presentan como una alternativa viable y asequible a estos sistemas de cubicación (White *et al.*, 2016; Acuna y Sosa, 2019; Mitrofavnos *et al.*, 2019).

No obstante, uno de los problemas de los métodos de cubicación basados en el uso de nubes de puntos es que los modelos generados contienen puntos del cargamento de madera, pero también del camión de carga, lo que requiere de su tratamiento para eliminar estos últimos. Puesto que la eliminación manual de estos puntos resulta demasiado costosa, algunos autores han tratado de segmentar los puntos correspondientes a la pila de madera comprobando si su distribución espacial se ajusta a la circularidad típica de un tronco (Sikora *et al.*, 2019). Por otra parte, el desarrollo de las redes neuronales convolucionales (CNN) ha permitido la aplicación de algoritmos de segmentación a datos 3D, como

son las nubes de puntos (Maturana y Scherer, 2015). Sin embargo, a pesar del papel predominante de las CNN en el campo de la visión artificial (Zhiqiang y Jun, 2017; Aloysius y Geetha, 2018), ningún estudio ha evaluado la viabilidad de este tipo de modelos para la segmentación automática de modelos 3D de cargamentos de madera. En este sentido, el modelo CNN desarrollado por THOMAS *et al.* (2019) resulta de gran interés, ya que es capaz de analizar variables como el color RGB de los puntos, además de su distribución local, para determinar la clase a la que pertenecen de manera computacionalmente eficiente.

Atendiendo a lo expuesto con anterioridad, se definieron los siguientes objetivos para el presente estudio: i) estudiar la viabilidad de los métodos de reconstrucción SfM para la cubicación de cargamentos de madera, ii) evaluar la capacidad de los modelos CNN para aislar los puntos pertenecientes al cargamento de madera, y iii) evaluar el efecto de la segmentación de la nube de puntos en la estimación del volumen de madera. Así pues, el fin de este estudio es probar la hipótesis de que el uso combinado de modelos CNN y de técnicas de reconstrucción SfM ofrece una alternativa viable y precisa a otros métodos de cubicación más costosos y difíciles de implementar en condiciones operativas.

## METODOLOGÍA

### Obtención de los datos

En el presente estudio se obtuvieron datos de 7 camiones de carga que transportaban trozas de *Eucalyptus nitens* H. Deane & Maiden al aserrado Surrey hills, en Tasmania, Australia. Para ello, se empleó un UAV modelo Phantom 4 Pro v2.0, desarrollado por la compañía DJI, para tomar imágenes con una resolución de 5.472x3.078 píxeles desde varios ángulos del cargamento (Tabla 1).

El vuelo del dron se programó para que sobrevolase la parte superior del cargamento y trazase círculos en torno al camión a una altura comprendida entre los 11,4 y los 24,6 metros, tomando fotografías a intervalos regulares. Como resultado,



**Figura 1.** Diferentes posiciones desde las que se tomaron las fotografías de un cargamento de madera; posiciones representadas con rectángulos azules

se obtuvieron un promedio de 133,1 imágenes de cada cargamento, variando el número de imágenes de 119 a 157 (Fig. 1).

### Generación del modelo 3D

Una vez adquiridas las imágenes, se procedió a su procesamiento empleando la versión 1.7.2 del programa comercial de modelado 3D Agisoft Metashape Professional™, el cual aplica algoritmos de SfM siguiendo un flujo de trabajo lineal. En primer lugar, se estimó la posición y orientación de la cámara en cada imagen mediante el algoritmo de emparejamiento de caracteres SIFT (Lowe, 2004), lo que permitió realizar una primera estimación de la geometría 3D del cargamento y generar una nube de puntos dispersa sin escala definida de entre 114.319 y 909.991 puntos, con un promedio de 440.872,7 puntos por cargamento.

Tras esto, se procedió a la aplicación de un algoritmo de emparejamiento de imágenes por estereoscopia multivista (MVS) para generar una nube de puntos densa de alta calidad del cargamento escalada y con unas unidades definidas, dando lugar a nubes de

entre 3.717.829 y 45.959.620 puntos, con un promedio de 12.578.920 de puntos por cargamento, donde cada punto posee unas coordenadas X, Y y Z, además de un color RGB. Estas nubes se generaron con una densidad de puntos elevada, llegando a superar a la obtenida por métodos láser (Acuna y Sosa, 2019), ya que una mayor densidad implica una mejor reconstrucción de la superficie del objeto de estudio. Esta reconstrucción se llevó a cabo generando una malla a partir de la nube de puntos densa de modo que cubriese la superficie del cargamento. Puesto que esta malla encierra un espacio tridimensional en su interior, es posible estimar el volumen del objeto. Finalmente, se empleó la información de las fotografías empleadas para reconstruir el modelo para añadir color al modelo 3D (Fig. 2).

Una vez generado un modelo 3D con un volumen medible, se procedió a eliminar manualmente las partes del modelo no pertenecientes al cargamento de madera. Esta tarea se llevó a cabo mediante la versión 21.1.1.8 del programa de edición 3D Autodesk® Recap™ Photo. Como resultado, se pudo estimar el volumen

**Tabla 1.** Especificaciones técnicas del modelo Phantom 4 Pro v2.0.

Modelo de la cámara	FC6310S
Píxeles efectivos	20 millones
Sensor	1" (13,2 x 8,8 mm) CMOS
Resolución	5.472 x 3.078 píxeles
Distancia focal	8,8 mm
Tamaño del píxel	2,53 x 2,53 µm

bruto de los cargamentos de madera, si bien algunas partes del remolque difíciles de eliminar quedaron incluidas en el modelo (Fig. 3).

### Segmentación automática

Como se mencionó anteriormente, los cargamentos de madera se separaron manualmente del resto del modelo, lo que resulta ineficiente y costoso. Así pues, en el presente estudio se evaluó la viabilidad de las CNN para segmentar la nube de puntos densa y reconstruir la malla del cargamento de madera de manera automática. Para ello, se empleó el modelo KPConv (Thomas *et al.*, 2019), ya que es robusto frente a densidades de puntos variables y permite analizar el color de los puntos para realizar la segmentación. Además, resulta





Figura 2. Malla de un cargamento generada a partir de la nube de puntos densa

computacionalmente eficiente, lo que permite entrenar el modelo y obtener predicciones de manera rápida. Para extraer la información relevante, el modelo KPConv realiza un muestreo a partir de la nube de puntos densa empleando una esfera, dentro de la cual se definen una serie de puntos o *kernels*, que sirven para determinar la función convolucional aplicada en función de la distancia a los *kernels*. Esta función se aplica entonces a los puntos muestreados, de modo que el modelo tiene en cuenta tanto la distribución espacial de los puntos dentro de la esfera, como las variables asociadas a cada punto, como es su color RGB.

Con el fin de entrenar este modelo se preparó una base de datos de 19 cargamentos, de los cuales solamente siete de ellos fueron cubiertos en este estudio. En esta base de datos las nubes de puntos densas fueron manualmente segmentadas diferenciando las clases “terreno”, “vehículo” y “madera”, a excepción de las nubes correspondientes a los cargamentos 3, 5, 6 y 7, que sirvieron para validar el modelo. Para ello, se empleó la herramienta de etiquetado Pointly<sup>1</sup>, la cual permite seleccionar fragmentos de la nube de puntos y asignarles una clase determinada de manera semiautomática (Fig. 4).

Una vez segmentadas las nubes de puntos, se procedió al entrenamiento del modelo empleando la plataforma de computación en la




Figura 3. Modelo 3D de un cargamento de madera

nube Google Colaboratory<sup>2</sup> y el código puesto a disposición de manera libre por Open3D<sup>3</sup>. Hecho esto, el modelo se utilizó para segmentar los cargamentos de validación de manera automática, de modo que los puntos correspondientes a las trozas apiladas pudiesen ser separados del resto, y se evaluó su exactitud siguiendo la Ecuación 1.


$$\text{Exactitud} = \frac{PR + NR}{PR + NR + FP + FN}$$

Donde *PR* es el número de positivos reales (detecciones correctas), *NR* el número de negativos reales (puntos correctamente clasificados como “no madera”), *FP* el número de falsos positivos (puntos falsamente clasificados como “madera”) y *FN* el número de falsos negativos (puntos falsamente clasificados como “no madera”).

Tras esto, se procedió a la generación de una malla empleando el algoritmo de reconstrucción de superficie de Poisson, propuesto por KAZHDAN *et al.* (2006) e implementado por Open3D, y se eliminaron manualmente pequeñas impurezas del modelo reconstruido empleando el programa Autodesk® Recap™ Photo (Fig. 5).

### Estimación del volumen sólido

La estimación del volumen sólido del cargamento se realizó ajustando un modelo de regresión lineal entre la variable independiente “volumen bruto” y la variable dependiente “volumen sólido”. Para ello, se midieron manualmente el diámetro de la sección mayor y de la sección menor de las trozas con precisión milimétrica, además de su longitud redondeando al decímetro más próximo. Posteriormente, se calculó el




**Figura 4.** Cargamento segmentado manualmente; en rojo la clase "terreno", en azul la clase "vehículo" y en verde la clase "madera"

volumen sólido empleando la fórmula de Smalian (ver Ecuación 2).

$$Vs = \frac{\pi}{8} * (D_1^2 + D_2^2) * L$$

Donde  $V_s$  es el volumen sólido ( $m^3$ ),  $D_1$  es el diámetro de la sección mayor (m),  $D_2$  es el diámetro de la sección menor (m) y  $L$  es la longitud de la troza (m).

Una vez hecho esto, el volumen sólido medido manualmente se comparó con el volumen sólido estimado mediante SfM y regresión lineal, y se calculó el error relativo y absoluto cometido de las predicciones. El modelo ajustado para los siete cargamentos sirvió también para evaluar los cuatro cargamentos segmentados de manera automáticas, ya que la cantidad de muestras segmentadas fue demasiado reducida como para ajustar un modelo de regresión.



**Figura 5.** Malla reconstruida a partir de una nube de puntos segmentada con el modelo KPConv

**Tabla 2.** Resumen de la medición manual de los cargamentos

	Camión							Media	SD
	1	2	3	4	5	6	7		
Nº de trozas	186	229	245	270	218	257	285	241,4	31,0
Longitud media (m)	5,47	5,64	5,61	5,36	5,72	5,71	5,40	5,56	0,14
Diámetro menor (mm)	162,9	151,0	138,3	121,7	144,0	138,2	129,8	140,8	12,5
Diámetro mayor (mm)	205,6	211,0	193,9	174,7	190,3	182,8	170,1	189,8	14,0

## RESULTADOS

### Medición de los cargamentos

En total se midieron 1690 trozas con un promedio de 241,43 trozas por cargamento. Estas tuvieron una longitud media de 5,56 metros, variando desde los 5,36 a los 5,72 m. En cuanto al diámetro menor, este varió desde los 121,7 hasta los 162,9 mm, tomando un valor promedio de 140,8 mm, mientras que el diámetro mayor varió desde los 170,1 hasta los 211,0 mm, con un valor promedio de 189,8 mm (ver Tabla 2).

Por otra parte, el volumen sólido real varió desde los 28,80 hasta los

39,19  $m^3$ , tomando un promedio de 32,91  $m^3$ . En lo que a SfM respecta, el volumen bruto estimado mediante

reconstrucción 3D varió entre los 48,35 y los 60,51  $m^3$ , con un promedio de 52,87  $m^3$ . El ratio entre el volumen



sólido y el volumen bruto osciló entre 0,58 y 0,65, tomando un valor promedio de 0,62, así como con la práctica común de emplear un coeficiente de apilado de 0,66 cuando se cubican pilas de madera (ver Tabla 3).

**Estimación del volumen sólido**

Tras ajustar el modelo de regresión lineal entre la variable dependiente “volumen sólido” y la variable independiente “volumen bruto”, se observó que únicamente la variable “volumen bruto” fue significativa (valor de  $p < 0,05$ ), ya que el intercepto presentó un valor de  $p$  de 0,83. Teniendo en cuenta que el volumen sólido es nulo cuando el volumen bruto es cero, se reajustó un modelo de regresión lineal sin intercepto (Fig. 6), dando como resultado un  $R^2$  ajustado de 0,83 y un error estándar de 1,322. Además, el valor de  $p$  de la variable independiente “volumen bruto” fue inferior a 0,001. Así pues, la ecuación resultante del ajuste de regresión lineal quedó como sigue (Ecuación 3):

Vol. sólido (m³) = 0,623 x Vol. bruto (m³)

Como resultado de aplicar el modelo, el error entre el volumen sólido real y estimado osciló entre -1,51 y 2,07 m³, si bien los valores positivos y negativos se cancelaron entre sí, siendo su valor promedio de tan solo -0,01 m³, lo que supone un error inferior al -0,2 %. No obstante, como resultado de esta variabilidad, la desviación típica del error fue de 1,22 m³. En cuanto al error absoluto, este varió desde los 0,16 hasta los 2,07 m³,

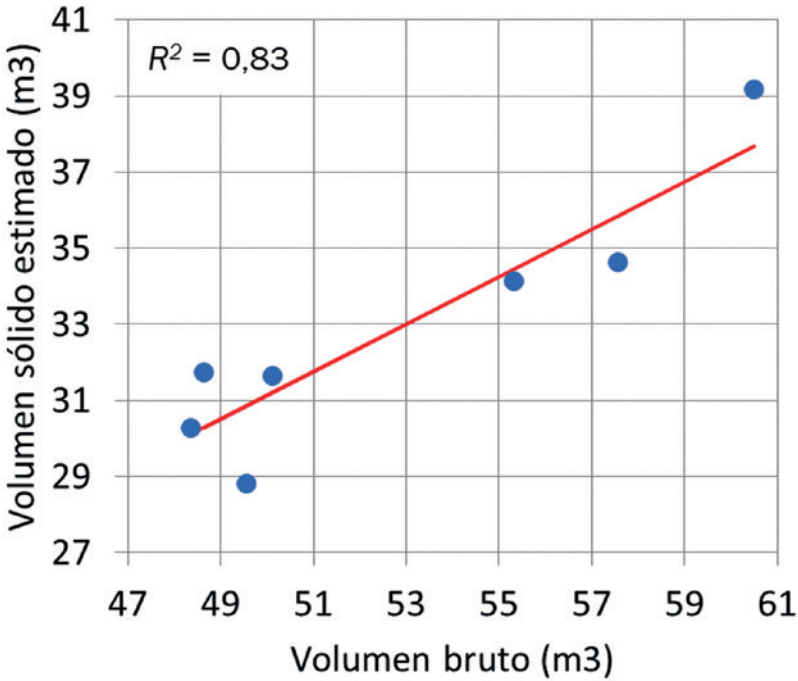


Figura 6. Modelo de regresión entre el volumen bruto y el volumen sólido de los cargamentos de madera

con un valor promedio de tan solo 1,03 m³, lo que equivale a una desviación absoluta máxima del 7,19 % y valor un promedio del 3,15 % (ver Tabla 3).

**Segmentación de la nube de puntos**

El algoritmo fue capaz de separar correctamente los puntos correspondientes al cargamento de madera de los correspondientes al camión, alcanzando una exactitud del 98,2 % durante el entrenamiento (Fig. 7). No obstante, cabe destacar que las nubes de puntos correspondientes a pilas de madera requirieron de un tratamiento manual para eliminar puntos aislados que pudiesen comprometer la calidad de la

reconstrucción 3D.

En cuanto a la estimación del volumen sólido, el error cometido varió entre -1,81 y 1,25 m³, tomando un valor promedio de tan solo -0,30 m³ (-0,80 %) y un valor de la desviación típica de 1,10 m³. Por otra parte, el error absoluto varió desde los 0,02 hasta los 1,81 m³, siendo su valor promedio de tan solo 0,92 m³, lo que equivale a una desviación absoluta máxima del 5,92 % y valor un promedio del 2,77 % (ver Tabla 4). Estos valores son similares a los obtenidos para los camiones 3, 5, 6 y 7 procesados manualmente, ya que en ese caso el error promedio fue del -0,65 %, mientras que el error absoluto promedio fue del 1,60 %.

Tabla 3. Resumen de la estimación del volumen sólido y del error cometido por el modelo

	Cargamento							Media	SD
	1	2	3	4	5	6	7		
Volumen sólido real (m³)	31,74	39,19	34,63	28,80	31,64	34,12	30,27	32,91	3,18
Volumen bruto estimado (m³)	48,63	60,51	57,57	49,57	50,11	55,33	48,35	52,87	4,53
Ratio vol. Sólido/vol. Bruto	0,65	0,65	0,60	0,58	0,63	0,62	0,63	0,62	0,02
Volumen sólido estimado (m³)	30,28	37,68	35,85	30,87	31,21	34,46	30,11	32,92	2,82
Error (m³)	1,46	1,51	-1,22	-2,07	0,43	-0,34	0,16	-0,01	1,22
Error (%)	4,59	3,85	-3,53	-7,19	1,37	-0,99	0,53	-0,19	3,83
Error absoluto (m³)	1,46	1,51	1,22	2,07	0,43	0,34	0,16	1,03	0,67
Error absoluto (%)	4,59	3,85	3,53	7,19	1,37	0,99	0,53	3,15	2,19




Figura 7. Resultado de la segmentación automática de un cargamento de madera; en rojo la clase "terreno", en azul la clase "vehículo" y en verde la clase "madera"

## DISCUSIÓN

El principal objetivo de este estudio fue demostrar la viabilidad de las técnicas SfM para ofrecer estimaciones fiables del volumen sólido de cargamentos de madera apilada. Además, se trató de mostrar la capacidad de los modelos CNN para separar automáticamente las partes correspondientes a las pilas de madera de las partes del vehículo y del terreno. Los resultados de este estudio muestran que el empleo de técnicas SfM para la estimación del volumen sólido de madera apilada sobre camiones es, no solo viable, sino que ofrece una precisión comparable a la de métodos mucho más costosos, como es el escaneo láser. Por ejemplo, NYLINDER *et al.* (2008) reportaron errores que variaron desde -4,5 % hasta 1,7 %, los cuales fueron inferiores a los obtenidos en este estudio, ya que estos variaron entre -4,59 % y 7,19 %. No obstante, el error promedio obtenido en este estudio resultó muy bajo, ya que los errores por exceso se vieron compensados por los errores por defecto, dando como resultado un error de tan solo -0,2 %.

Estos resultados se encuentran en consonancia con lo que Acuna y Sosa (2019) reportaron, si bien el error obtenido en este estudio resulta ligeramente superior, ya que en el anterior obtuvieron un error promedio

Tabla 4. Resumen de la estimación del volumen sólido y del error cometido por el modelo para los cargamentos segmentados mediante KPConv

	Cargamento				Media	SD
	3	5	6	7		
Volumen sólido real (m <sup>3</sup> )	34,63	31,64	34,12	30,27	32,67	1,79
Volumen bruto estimado (m <sup>3</sup> )	56,60	48,80	57,69	48,64	52,93	4,23
Ratio vol. Sólido/vol. bruto	0,61	0,65	0,59	0,62	0,62	0,02
Volumen sólido estimado (m <sup>3</sup> )	35,25	30,39	35,93	30,29	32,96	2,63
Error (m <sup>3</sup> )	-0,62	1,25	-1,81	-0,02	-0,30	1,10
Error (%)	-1,78	3,95	-5,29	-0,07	-0,80	3,33
Error absoluto (m <sup>3</sup> )	0,62	1,25	1,81	0,02	0,92	0,67
Error absoluto (%)	1,78	3,95	5,29	0,07	2,77	2,00

de -0,05 % y de 1,7 % en términos absolutos, frente al -0,2 % y 3,15 % observado en el presente trabajo. Dado que el método que se empleó en los dos estudios fue muy similar, es probable que la fuente del error se encuentre en el hecho de que los modelos generados no fueron depurados tan exhaustivamente como se hizo en el anterior estudio, pues ciertas partes del remolque quedaron incluidas e influyeron en el ajuste del modelo de regresión lineal. Así pues, como ya constataron Acuna y Sosa (2019), la principal ventaja de la cubicación de cargamentos mediante SfM es su bajo coste económico, el cual resulta varias veces inferior al de la tecnología láser (Mlambo *et al.*, 2017). No obstante, las condiciones

ambientales y de iluminación juegan un papel importante en el resultado final de la reconstrucción 3D y pueden suponer una fuente importante de error si no se tienen en cuenta. Además, el tiempo de procesamiento de los datos puede resultar elevado, lo que depende principalmente de la cantidad de imágenes empleadas en la reconstrucción, de los parámetros del algoritmo de reconstrucción seleccionados y de la potencia computacional de que se dispone.

Otra debilidad de este método es la necesidad de editar manualmente los modelos 3D para eliminar partes pertenecientes al remolque o al vehículo de carga, por lo que algunos autores trataron de automatizar el proceso (Sikora *et al.*, 2019). En

este sentido, los resultados de la segmentación obtenidos en el presente estudio mediante el modelo KPConv son equiparables a los reportados por Sikora *et al.* (2019). Además, cuando se estimó el volumen sólido empleando los cargamentos segmentados, el error cometido fue solo del -0,80 %, siendo su valor absoluto del 2,77 %. Estos resultados, sugieren que KPConv puede utilizarse para generar modelos 3D con una calidad similar a los editados manualmente, reduciendo así el tiempo requerido para la cubicación de pilas de madera mediante SfM. No obstante, un cierto grado de trabajo manual fue necesario, ya que aparecieron algunas impurezas durante la reconstrucción del modelo. En cualquier caso, estos resultados se obtuvieron a partir de un número reducido de muestras, por lo que en futuros trabajos se evaluará un número mayor de cargamentos y se estudiará la posibilidad de depurar los modelos sin necesidad de edición manual.

## CONCLUSIÓN

El empleo de técnicas SfM se encuentra cada vez más extendido debido a su bajo coste económico y a la relativa facilidad de su aplicación. Si bien diversos autores probaron su viabilidad para cubicar cargamentos de madera apilada, estas no se han implementado a nivel comercial ni han alcanzado el grado de madurez que posee el escaneo láser. Por otra parte, los modelos CNN ofrecen la posibilidad de automatizar parte del proceso de reconstrucción de los modelos 3D, lo cual no ha recibido suficiente atención en el pasado. Por ello, el principal objetivo de este trabajo fue comprobar la viabilidad de los métodos de cubicación por SfM, así como demostrar la capacidad de los modelos CNN para hacer más eficientes estos métodos. Los resultados obtenidos en este estudio respaldan lo reportado por otros autores, los cuales equipararon la precisión de la cubicación por SfM con la cubicación por escaneo láser. En nuestro caso, el error promedio cometido en la estimación del volumen sólido de los cargamentos fue del -0,19 % y del 3,15 % en términos absolutos. Por otra parte,

la segmentación mediante CNN alcanzó una exactitud del 98,2 %. Además, el error promedio cometido en la cubicación de los cargamentos segmentados mediante KPConv fue del -0,80 % y del 2,77 % en términos absolutos, valores próximos a los obtenidos para esos mismos cargamentos mediante depuración manual, los cuales fueron del -0,65 % y del 1,60 % respectivamente. Estos resultados corroboran que la cubicación mediante SfM puede utilizarse como una herramienta precisa y de bajo coste para cubicar madera apilada. Además, el empleo

del modelo KPConv para separar la pila de madera del resto de la escena permitió reducir enormemente la labor manual requerida tras la reconstrucción 3D. En futuros trabajos se explorará en mayor profundidad el uso de modelos CNN para automatizar el proceso, así como la manera de reducir su coste computacional y de mejorar la calidad de las estimaciones.

<sup>1</sup><https://pointnet.ai/>

<sup>2</sup><https://colab.research.google.com/>

<sup>3</sup><https://github.com/isl-org/Open3D>

## Bibliografía

- Acuna, M.; Sosa, A.; 2019. Automated volumetric measurements of truckloads through multi-view photogrammetry and 3D reconstruction software. *CROJFE*. 40(1): 151-162.
- Aloysius, N.; Geetha, M.; 2018. A review on deep Convolutional Neural Networks. En: *JCCSP*. p. 588-592.
- Cind, A.B. 2021. Roundwood Measurement & Defect Detection. Disponible en: <https://www.cind.se/timber-industry>. Acceso: 18/12/21.
- Gruen, A. 2008. Scientific-technological developments in photogrammetry and remote sensing between 2004 and 2008. En: *ISPRS Archives*. Beijing. p. 39-44.
- Harwin, S.; Lucieer, A.; 2012. Assessing the accuracy of georeferenced point clouds produced via multi-view stereopsis from unmanned aerial vehicle (UAV) imagery. *Remote Sensing* 4(6): 1573-1599.
- Janák, K. 2005. Differences in volume of round timber caused by Different determination methods. *Drvna industrija* 56(4): 165-170.
- Janák, K. 2007. Differences in round wood measurements using electronic 2D and 3D systems and standard manual method. *Drvna industrija* 58(3): 127-133.
- Kazhdan, M.; Bolitho, M.; Hoppe, H. 2006. Poisson surface reconstruction. In *Proceedings of the fourth Eurographics symposium on Geometry processing*, Vol. 7.
- Knyaz, V.A.; Maksimov, A.A. 2014. Photogrammetric technique for timber stack volume control. *The International Archives of Photogrammetry, Remote Sensing and Spatial Information Sciences*, 40(3): 157.
- Lowe, D.G. 2004. Distinctive image features from scale-invariant keypoints. *International journal of computer vision*, 60, 91-110.
- Mabema 2020. Mabema GPV: Ett revolutionerande sätt att volymmäta timmertravar pålastbil. Disponible en: <https://mabema.se/>. Acceso: 21/01/21.
- Maturana, D.; Scherer, S. 2015. Voxnet: A 3d convolutional neural network for real-time object recognition. In *2015 IEEE/RSJ international conference on intelligent robots and systems (IROS)* (pp. 922-928).
- Mitrofanov, I.; Cekule, M.; Cabs, K. 2019. Problems during scientific research and designing integration. *Systematic cybernetic and Information*, 17(1): 117-128.
- Mlambo, R.; Woodhouse, I. H.; Geerard, F.; Anderson, K.; 2017. Structure from motion (SfM) photogrammetry with drone data: A low cost method for monitoring greenhouse gas emissions from forests in developing countries. *Forests*, 8(3): 68.
- Nylinder, M.; Kubénka, T.; Hultnäs, M.; 2008. Roundwood measurement of truck loads by laser scanning. A field study at Arauco pulp mill Nueva Aldea. Informe técnico. Woodtech.
- P3D; 2020. P3D Truck: laser measurement system for wood loads. Disponible en: <http://www.p3d.cl/>. Acceso: 14/10/21.
- Sikora, J.; Fojtík, D.; Gebauer, J.; Podešva, P.; Mihola, M. 2019. Preparation of 3D models of Trucks for Timber Load Analysis. In *2019 20th International Carpathian Control Conference (ICCC)* (pp. 1-4). IEEE.
- Snavely, N.; Seitz, S. M.; Szeliski, R. 2008. Modeling the world from internet photo collections. *International journal of computer vision*, 80, 189-210.
- Thomas, H.; Qi, C. R.; Deschaud, J. E.; Marcotequi, B.; Goulette, F.; Guibas, L.J. 2019. Kpconv: Flexible and deformable convolution for point clouds. In *Proceedings of the IEEE/CVF international conference on computer vision* (pp. 6411-6420).
- WOODTECH; 2020. Logmeter: Laser technology for measuring volume of logs loaded on moving. Disponible en: <http://www.woodtechms.com/>. Acceso: 14/10/21.
- Zhiqiang, W., Jun, L. 2017. A review of object detection based on convolutional neural network. In *2017 36th Chinese control conference (CCC)* (pp. 11104-11109). IEEE.